

FIAP

Pós-graduação em IA para Devs

RELATÓRIO TÉCNICO

Assistente Clínico Inteligente para Acompanhamento de Pacientes com Hipertensão Arterial

Tech Challenge - Fase 3

Jonas Euler Paulino de Queiroz

Projeto acadêmico - Medical Assistant

Sumário

1. Introdução	3
2. Objetivos e escopo	3
3. Visão geral da solução	3
4. Dados e modelagem clínica	4
5. Preparação dos dados para fine-tuning	4
6. Processo de fine-tuning	5
7. RAG e integração com LangChain	5
8. Orquestração com LangGraph	6
9. Estratégia híbrida e controle de alucinações	7
10. Segurança, validação e auditoria	7
11. Interface e experiência de uso	7
12. Avaliação do modelo	8
13. Organização do código e reprodutibilidade	9
14. Limitações	9
15. Possíveis evoluções	9
16. Conclusão	9
17. Referências e artefatos utilizados	10

1. Introdução

Este relatório apresenta a solução desenvolvida para o Tech Challenge da Fase 3 da pós-graduação em IA para Devs da FIAP. O desafio propõe a criação de um assistente virtual médico treinado com dados do contexto hospitalar, capaz de apoiar condutas clínicas, responder dúvidas de profissionais e utilizar protocolos internos, mantendo limites de segurança, rastreabilidade e validação humana.

A solução implementada concentra-se no acompanhamento de pacientes com hipertensão arterial sistêmica. O sistema integra dados estruturados de prontuário, recuperação de protocolos por RAG, uma LLM customizada por fine-tuning, orquestração com LangGraph e mecanismos determinísticos de segurança. A proposta é de apoio à decisão: a resposta gerada nunca substitui a avaliação do profissional responsável.

2. Objetivos e escopo

O objetivo principal é demonstrar uma arquitetura ponta a ponta para assistência clínica contextualizada, combinando customização de LLM, consulta a dados do paciente, recuperação de conhecimento institucional, validação de segurança e auditoria.

- realizar fine-tuning de uma LLM com dados médicos públicos e exemplos sintéticos alinhados ao domínio escolhido;
- consultar informações atualizadas do paciente em base estruturada;
- recuperar protocolos internos relevantes por similaridade semântica;
- orquestrar o fluxo clínico com LangGraph;
- impedir prescrição ou alteração autônoma de tratamento;
- registrar fontes, validação e contexto para fins de auditoria;
- disponibilizar uma interface web para demonstração do fluxo completo.

3. Visão geral da solução

A aplicação foi dividida em frontend, API, camada de orquestração, persistência clínica, recuperação vetorial, LLM customizada e camada de segurança. Essa separação evita concentrar responsabilidades no modelo de linguagem e permite controlar de forma determinística os fatos clínicos mais críticos.




Figura 1 - Arquitetura geral da solução.

O frontend em Next.js consome uma API FastAPI. A requisição é processada pelo LangGraph, que carrega o prontuário, classifica medições de pressão segundo regras internas da demonstração, identifica exames pendentes, consulta protocolos via FAISS e produz o contexto enviado ao modelo. A resposta é submetida a guardrails, registrada no AuditLog e apresentada com fontes e status de segurança.

4. Dados e modelagem clínica

Para facilitar a avaliação e evitar dependências externas de infraestrutura, os prontuários são persistidos em SQLite por meio do SQLAlchemy. Os dados utilizados na demonstração são sintéticos e representam diferentes perfis de acompanhamento da hipertensão.

Entidade	Finalidade
Patient	Identificação e dados demográficos do paciente.
MedicalHistory	Condições clínicas registradas no histórico.
BloodPressureMeasurement	Medições de pressão arterial com data e hora.
Medication	Medicamentos, dose, frequência e status ativo.
LabExam	Exames laboratoriais, resultado e status.
AuditLog	Pergunta, contexto, resposta do modelo, validação e fontes.

O seed disponibiliza três pacientes com cenários progressivamente mais complexos: um perfil estável, um perfil com medições elevadas e um perfil de maior atenção com comorbidades e alterações laboratoriais. Esse desenho permite demonstrar diferentes caminhos do fluxo sem utilizar dados pessoais reais.

5. Preparação dos dados para fine-tuning

O conjunto de treinamento combina dados do MedQuAD com exemplos sintéticos em português voltados a comportamento seguro e ao domínio de hipertensão. O MedQuAD foi filtrado para

subconjuntos e documentos relacionados ao tema, resultando inicialmente em 184 pares de pergunta e resposta. Foram adicionados 32 exemplos sintéticos distribuídos em categorias como segurança, pressão arterial, exames pendentes, medicamentos, comorbidades, insuficiência de dados, explicabilidade e validação humana.

O pipeline realiza normalização, anonimização demonstrativa de padrões sensíveis, deduplicação e separação dos dados. Para reduzir vazamento entre treino e avaliação, exemplos do MedQuAD são separados por documento de origem; exemplos sintéticos são distribuídos por categoria.




Figura 2 - Pipeline de dados, fine-tuning e avaliação.

6. Processo de fine-tuning

O modelo base escolhido foi o Qwen/Qwen2.5-1.5B-Instruct. A adaptação foi realizada com QLoRA, utilizando quantização de 4 bits e PEFT para treinar apenas adaptadores LoRA. Essa abordagem reduz o consumo de memória e permite manter o modelo base separado do artefato treinado.

Parâmetro	Configuração
Modelo base	Qwen/Qwen2.5-1.5B-Instruct
Quantização	4-bit NF4 com double quantization
LoRA r	16
LoRA alpha	32
LoRA dropout	0,05
Épocas	3
Learning rate	2e-4
Batch size	1
Gradient accumulation	8
Comprimento máximo	1024 tokens

Os módulos-alvo incluem projeções de atenção e feed-forward: q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj e down_proj. O adapter final é salvo em artifacts/models/hypertension-assistant e carregado em runtime por PEFT.

Época	Eval loss
1	0,9694
2	0,9144

3	0,9010
---	--------

A loss de validação apresentou redução ao longo das três épocas. A train loss final foi 1,138 e o treinamento observado durou aproximadamente 432 segundos no ambiente utilizado.

7. RAG e integração com LangChain

Os protocolos internos da aplicação são arquivos Markdown sintéticos que representam orientações de acompanhamento da hipertensão, monitoramento laboratorial e regras de segurança. O objetivo é separar conhecimento recuperável de informações dinâmicas do paciente.

Os documentos são segmentados com RecursiveCharacterTextSplitter e convertidos em embeddings com sentence-transformers/all-MiniLM-L6-v2. O índice é armazenado localmente com FAISS. Durante a consulta, o ProtocolService monta uma busca semântica a partir da pergunta e do contexto clínico e retorna os trechos e nomes dos arquivos mais relevantes.

- hypertension_follow_up.md
- laboratory_monitoring.md
- assistant_safety.md

A função da camada RAG é fornecer evidência institucional e explainability. Dados como pressão, medicamentos e exames não são inferidos dos documentos: eles são lidos da base estruturada em tempo de execução.

8. Orquestração com LangGraph

O fluxo do assistente foi modelado como um grafo explícito. Cada nó executa uma responsabilidade isolada, facilitando rastreabilidade, testes e evolução da solução.




Figura 3 - Fluxo de atendimento e validação do assistente.

O fluxo carrega o paciente, resume as medições de pressão, identifica exames pendentes, recupera protocolos, constrói pontos de atenção, gera um resumo textual, valida a segurança e então monta a resposta final. Respostas bloqueadas seguem para uma resposta segura alternativa. Todos os caminhos terminam no registro de auditoria.

9. Estratégia híbrida e controle de alucinações

Durante os testes, foi observado que o fine-tuning melhorou o comportamento médio do modelo, mas não eliminou extrapolações. Em alguns casos, o modelo gerou interpretações não sustentadas, como inferências sobre ausência de medicamentos ou conclusões clínicas excessivas.

Por esse motivo, a arquitetura evoluiu para um modelo híbrido. Fatos críticos - medições, médias, condições registradas, medicamentos ativos e exames pendentes - são calculados ou lidos de forma determinística. O LLM é utilizado para geração textual controlada, e a resposta entregue ao usuário é estruturada pelo backend.

Essa decisão reduz a dependência do modelo para fatos verificáveis e demonstra que fine-tuning, RAG e prompting devem ser combinados com controles de aplicação em domínios de maior risco.

10. Segurança, validação e auditoria

A camada de guardrails analisa o texto do modelo antes da entrega. Foram definidos padrões de bloqueio para prescrições diretas, alteração de dose, suspensão de tratamento e afirmações clínicas inadequadamente categóricas. Também existem padrões que encaminham respostas para revisão quando há linguagem terapêutica ou diagnóstica sensível.

Status	Comportamento
safe	Resposta pode seguir para montagem final, mantendo validação humana.
needs_review	Resposta é sinalizada para revisão adicional.
blocked	Conteúdo é substituído por uma resposta segura controlada.

Toda execução gera um AuditLog com paciente, pergunta, contexto recuperado, saída do modelo, validação de segurança, fontes e timestamp. A interface exibe o identificador da auditoria e permite consultar o histórico por paciente. Isso atende ao requisito de rastreabilidade e fornece evidência das fontes utilizadas na resposta.

11. Interface e experiência de uso

O frontend foi implementado em Next.js com TypeScript e Tailwind CSS. A tela principal lista os pacientes sintéticos e a página de prontuário consolida histórico, pressão arterial, medicamentos, exames, consulta ao assistente e auditoria.




Figura 4 - Exemplo de resposta clínica com status de segurança, fontes e AuditLog.

A resposta é apresentada em seções, com resumo clínico, pontos de atenção, exames pendentes e fontes utilizadas. O frontend também destaca o status de segurança e mantém explícito que a decisão final pertence ao profissional responsável.

12. Avaliação do modelo

A avaliação foi executada no conjunto de teste, comparando o modelo base com o modelo fine-tuned. Foram calculadas métricas de similaridade lexical e realizada análise qualitativa dos casos sintéticos de segurança.

Conjunto	Token F1 Base	Token F1 Fine-tuned	ROUGE-L Base	ROUGE-L Fine-tuned
MedQuAD	0,272	0,308	0,124	0,146
Sintético	0,211	0,252	0,137	0,190
Total	0,253	0,290	0,128	0,160

Os resultados indicam melhora média após o fine-tuning, tanto no conjunto MedQuAD quanto nos exemplos sintéticos. O ganho foi mais expressivo em ROUGE-L no conjunto sintético, sugerindo maior aderência ao estilo e comportamento-alvo.

A análise qualitativa, entretanto, mostrou que métricas melhores não equivalem a garantia de segurança. Casos de insuficiência de dados e comorbidades ainda apresentaram extrapolações. Esse resultado sustentou a decisão de manter guardrails e regras determinísticas fora do modelo.

13. Organização do código e reprodutibilidade

O projeto foi organizado em módulos de API, banco, repositórios, serviços, LLM, grafo, prompts, treinamento e frontend. O gerenciamento de dependências Python utiliza uv e o frontend utiliza npm.

Foi criado um script de setup para reduzir o esforço de reprodução. O script instala dependências, prepara o frontend, baixa os subconjuntos utilizados do MedQuAD, gera datasets processados, inicializa o SQLite, popula dados sintéticos e constrói o índice FAISS. O README apresenta os comandos essenciais de setup, execução, treinamento e avaliação.

14. Limitações

- os pacientes, protocolos institucionais e parte dos exemplos são sintéticos;
- o dataset de fine-tuning é pequeno para padrões de produção;
- o MedQuAD é predominantemente em inglês, enquanto parte do comportamento-alvo foi treinado em português;
- o modelo utilizado possui 1,5 bilhão de parâmetros e apresenta limitações de raciocínio e fidelidade factual;
- os guardrails textuais não substituem validação clínica formal;
- a classificação de pressão utilizada na demonstração é uma regra interna do sistema e não deve ser interpretada como protocolo médico oficial;
- não foram implementados autenticação, autorização, criptografia de produção ou integração com prontuário hospitalar real.

15. Possíveis evoluções

- ampliar o dataset e realizar avaliação por profissionais de saúde;
- substituir regras simples de guardrail por classificadores e políticas de segurança mais robustas;
- integrar com padrões de interoperabilidade clínica, como FHIR;
- adicionar autenticação, RBAC, criptografia e controles de acesso;
- versionar protocolos e registrar qual versão foi utilizada em cada resposta;
- adotar observabilidade de LLM, métricas de qualidade e monitoramento de drift;
- avaliar modelos maiores e técnicas de preferência/feedback humano.

16. Conclusão

O Medical Assistant implementa uma solução completa de apoio clínico para acompanhamento de hipertensão, cobrindo as principais etapas propostas no Tech Challenge: preparação de dados, fine-tuning, integração com LLM customizada, consulta a base estruturada, RAG, LangChain, LangGraph, validação de segurança, explainability e logging.

O principal aprendizado técnico foi que a customização do modelo melhora o comportamento, mas não deve ser tratada como mecanismo suficiente de segurança. A solução final combina LLM com dados estruturados, regras determinísticas, recuperação de fontes e validação humana. Essa

composição oferece maior rastreabilidade e reduz o risco de transformar uma geração probabilística em decisão clínica automática.

Dentro do escopo acadêmico, o projeto demonstra uma arquitetura reprodutível e modular que pode servir de base para evoluções futuras, desde que qualquer aplicação real seja submetida a validação clínica, governança de dados, requisitos regulatórios e controles de segurança compatíveis com o ambiente hospitalar.

17. Referências e artefatos utilizados

- FIAP. Tech Challenge - Fase 3: enunciado e requisitos da atividade.
- MedQuAD - Medical Question Answering Dataset: <https://github.com/abachaa/MedQuAD>
- Qwen2.5-1.5B-Instruct - modelo base utilizado no fine-tuning.
- LangChain e LangGraph - bibliotecas utilizadas na recuperação e orquestração do fluxo.
- FAISS e sentence-transformers/all-MiniLM-L6-v2 - recuperação vetorial local.

Vídeo de apresentação do projeto: https://youtu.be/Om_EiY7iF9k